

CRISP-DM – Prédiction de la Faillite d'Entreprise

Phase: Analyse et Nettoyage des Données

Jegham Mohamed
Génie Informatique – Data Science
Année Universitaire 2025–2026

Table des matières

1	Introduction	2
2	Compréhension des Données	2
2.1	Description du Dataset	2
2.2	Indicateurs Financiers Principaux	2
3	Analyse Exploratoire	2
3.1	Distribution de la Variable Cible	2
3.2	Qualité des Données	3
3.3	Analyse des Corrélations	3
3.4	Comparaison des Indicateurs par Statut	4
4	Nettoyage des Données	5
4.1	Étapes de Nettoyage	5
4.2	Résultat	5
5	Conclusion	5

1 Introduction

Ce rapport présente la phase d'**analyse exploratoire** et de **nettoyage des données** du projet de prédiction de la faillite d'entreprise, réalisée selon la méthodologie CRISP-DM (Cross-Industry Standard Process for Data Mining).

L'objectif de cette phase est de :

- Comprendre la structure et le contenu des données ;
- Identifier les problèmes de qualité des données ;
- Appliquer les traitements de nettoyage nécessaires ;
- Préparer les données pour la phase de modélisation.

Le jeu de données provient de la plateforme Kaggle (Company Bankruptcy Prediction) et contient des indicateurs financiers d'entreprises chinoises, avec une variable cible indiquant si l'entreprise a fait faillite ou non.

2 Compréhension des Données

2.1 Description du Dataset

Le dataset original contient :

- **6 819 observations** (entreprises) ;
- **96 variables** (1 variable cible + 95 indicateurs financiers) ;
- **Variable cible** : Bankrupt? — 0 = entreprise saine, 1 = entreprise en faillite.

2.2 Indicateurs Financiers Principaux

Les variables couvrent plusieurs dimensions de la santé financière des entreprises :

Catégorie	Exemples d'indicateurs
Rentabilité	ROA, Operating Gross Margin, Operating Profit Rate
Liquidité	Current Ratio, Quick Ratio, Cash/Total Assets
Endettement	Total debt/Total net worth, Debt ratio %, Net worth/Assets
Croissance	Total Asset Growth Rate, Net Value Growth Rate
Flux de trésorerie	Cash flow rate, Cash Flow to Sales, CFO to Assets

TABLE 1 – Catégories d'indicateurs financiers dans le dataset

3 Analyse Exploratoire

3.1 Distribution de la Variable Cible

La variable cible présente un **déséquilibre important** :

- **6 599** entreprises saines (96,77 %) ;
- **220** entreprises en faillite (3,23 %).




FIGURE 1 – Distribution de la variable cible **Bankrupt?**

Ce déséquilibre est caractéristique des problèmes de prédiction de faillite : la majorité des entreprises restent solvables. Des techniques telles que l’oversampling, l’undersampling ou l’utilisation de métriques appropriées (F1-score, AUC) seront nécessaires lors de la modélisation.

3.2 Qualité des Données

L’évaluation de la qualité a révélé les éléments suivants :

- **Valeurs manquantes** : Aucune (0 valeurs manquantes sur l’ensemble du dataset) ;
- **Doublons** : Aucun enregistrement dupliqué détecté ;
- **Types de données** : Toutes les variables sont numériques (float64 ou int64).

Le dataset est donc d’une qualité correcte en termes de complétude. Les valeurs aberrantes potentielles ont été identifiées sur certains indicateurs financiers (via la méthode IQR) ; elles reflètent cependant des situations réelles d’entreprises en forte difficulté et n’ont pas été supprimées systématiquement.

3.3 Analyse des Corrélations

La figure 2 présente la matrice de corrélation pour un échantillon d’indicateurs clés. Certaines variables sont fortement corrélées entre elles (ex. ratios de liquidité, ratios d’endettement), ce qui pourra influencer le choix des algorithmes (éviter la multicollinéarité) ou permettre une réduction de dimensionnalité.




FIGURE 2 – Matrice de corrélation des indicateurs financiers clés

3.4 Comparaison des Indicateurs par Statut

La figure 3 montre la distribution de quelques indicateurs (Current Ratio, Total debt/Total net worth, Debt ratio %) selon le statut de faillite. On observe des différences de tendance : les entreprises en faillite tendent à avoir des ratios de liquidité plus faibles et des niveaux d'endettement plus élevés, conformément aux hypothèses métier du projet.




FIGURE 3 – Distribution des indicateurs financiers par statut (faillite vs non-faillite)

4 Nettoyage des Données

4.1 Étapes de Nettoyage

Les opérations suivantes ont été réalisées :

1. **Suppression des doublons** : Aucun doublon détecté ; aucune ligne supprimée.
2. **Gestion des valeurs manquantes** : Aucune valeur manquante ; aucune action requise.
3. **Vérification des types** : Les types numériques sont cohérents.
4. **Nettoyage des noms de colonnes** : Suppression des espaces en début de nom pour faciliter le traitement.

4.2 Résultat

Le dataset nettoyé conserve les **6 819 observations** et **96 colonnes**. Il a été exporté au format CSV sous le nom `data_cleaned.csv` dans le dossier `output/`.

5 Conclusion

Cette phase d'analyse et de nettoyage a permis de :

- Caractériser le dataset : 6 819 entreprises, 95 indicateurs financiers, variable cible binaire ;
- Confirmer un fort déséquilibre de classes (3,23 % de faillites) à prendre en compte en modélisation ;
- Valider la bonne qualité des données (pas de valeurs manquantes ni de doublons) ;
- Identifier des corrélations et des différences de distribution entre entreprises saines et en faillite, cohérentes avec les hypothèses métier.

Les données sont prêtes pour la phase suivante : **préparation des données** (feature engineering, sélection de variables, partition train/test) et **modélisation**.