

CRISP-DM–Prédiction de la Faillite d'Entreprise

-Phase de modélisation-

Jegham Mohamed
Génie Informatique — Data Science
Année universitaire 2025–2026

Table des matières

1	Introduction et positionnement CRISP-DM	2
2	Données et protocole expérimental	2
2.1	Jeu de données et partition	2
2.2	Métriques	2
3	Prétraitement et pipeline d'apprentissage	3
4	Validation croisée sur le jeu d'entraînement	3
5	Résultats sur le jeu de test et choix du meilleur modèle	3
6	Courbe précision–rappel et choix du seuil de décision	5
6.1	Intérêt pour la classe minoritaire	5
6.2	Calibrage du seuil sans fuite d'information	5
6.3	Interprétation métier	7
7	Synthèse, limites et pistes	7
8	Conclusion	7

1 Introduction et positionnement CRISP-DM

Ce document décrit la **phase de modélisation** du projet *prédiction de la faillite d'entreprise*, dans le cadre de la méthodologie **CRISP-DM**. Elle fait suite à la compréhension des données et au nettoyage (rapport d'analyse exploratoire). L'objectif est d'apprendre un classifieur binaire à partir d'indicateurs financiers, avec une variable cible **Bankrupt?** (0 = entreprise saine, 1 = faillite).

Livrables automatisés. L'exécution du script Python `modeling_bankruptcy.py` produit notamment :

- `output/model_results.csv` — métriques **test** et scores de **validation croisée** (moyenne $\pm$ écart-type sur le train) ;
- `output/best_model.pkl` — pipeline retenu (scaler + SMOTE + estimateur) ;
- figures : distribution, corrélation, ROC, **courbe précision-rappel**, matrices de confusion (seuil 0,5 et seuil optimal) ;
- `output/threshold_metrics.json` et `output/run_metadata.json` — seuil optimal et métadonnées de run.

Commande recommandée. Compiler ce rapport **après** avoir lancé, depuis la racine du projet :

```
python modeling_bankruptcy.py
```

(option `-no-xgb` pour désactiver XGBoost si besoin).

2 Données et protocole expérimental

2.1 Jeu de données et partition

Le fichier source est `data.csv` (ou `output/data_cleaned.csv` après la phase de nettoyage). Les observations sont réparties ainsi :

- **Jeu d'entraînement** : 80 % des lignes, tirage **stratifié** sur **Bankrupt?** (même proportion de faillites que dans la population).
- **Jeu de test** : 20 %, utilisé **une seule fois** pour l'évaluation finale et les graphiques de généralisation (sans participer au choix des hyperparamètres ni au seuil, voir section 6).

2.2 Métriques

Pour la classe *faillite* (positif) :

- **Précision** : part d'alertes correctes parmi les entreprises classées en faillite.
- **Rappel (sensibilité)** : part de faillites réelles effectivement détectées.
- **F1-score** : moyenne harmonique de la précision et du rappel, adaptée au **déséquilibre** des classes.
- **ROC-AUC** : capacité de discrimination globale des scores de probabilité.
- **AP (Average Precision)** : aire sous la courbe précision-rappel, utile lorsque la classe positive est rare.

3 Prétraitement et pipeline d'apprentissage

Chaque modèle est encapsulé dans un **pipeline** `imblearn` :

`StandardScaler → SMOTE → classifieur`

StandardScaler. Mise à l'échelle des prédicteurs (moyenne nulle, variance unitaire), **ajustée uniquement sur les données d'entraînement** de chaque pli.

SMOTE. Sur-échantillonnage synthétique de la classe minoritaire sur le **train** uniquement, afin de limiter le biais vers la classe majoritaire. Le jeu de test n'est **jamais** sur-échantillonné.

Modèles comparés. Régression logistique, arbre de décision, forêt aléatoire, gradient boosting (et XGBoost si installé). La **forêt aléatoire** fait l'objet d'une **recherche sur grille** (`GridSearchCV`) en optimisant le **F1-score** sur validation croisée stratifiée à 5 plis.

4 Validation croisée sur le jeu d'entraînement

Après entraînement (et après sélection des hyperparamètres pour la forêt aléatoire), un **second** passage en validation croisée est effectué : on clone le pipeline final et on recalcule, sur le **train** uniquement, les scores F1, ROC-AUC et accuracy sur 5 plis stratifiés. Les colonnes correspondantes dans `model_results.csv` sont :

- `cv_f1_mean`, `cv_f1_std`;
- `cv_roc_auc_mean`, `cv_roc_auc_std`;
- `cv_accuracy_mean`, `cv_accuracy_std`.

Cela permet de juger la **stabilité** des performances (écart-type entre plis) en plus du score sur le jeu de test. Une forte variance entre plis peut signaler une sensibilité au découpage ou à la rareté de la classe positive.

5 Résultats sur le jeu de test et choix du meilleur modèle

Le **meilleur modèle** est celui qui maximise le **F1-score sur le test**, puis la **ROC-AUC** en cas d'égalité. Les métriques au **seuil par défaut** de `predict` (0,5 sur la probabilité de la classe 1) sont reportées dans `model_results.csv`.




FIGURE 1 – Courbe ROC sur le jeu de test — modèle retenu (discrimination globale).




FIGURE 2 – Matrice de confusion (seuil de probabilité = 0,5). Effectifs et pourcentages par ligne (vraie classe).




FIGURE 3 – Importance des variables (top 25) pour le modèle retenu.

6 Courbe précision–rappel et choix du seuil de décision

6.1 Intérêt pour la classe minoritaire

La courbe **précision–rappel** (PR) met l’accent sur la performance pour la classe *faillite*. Elle est souvent plus informative que la seule ROC lorsque les classes sont **très déséquilibrées**. L’aire sous la courbe PR correspond à l’**Average Precision (AP)**.

6.2 Calibrage du seuil sans fuite d’information

Le seuil sur la probabilité prédite $P(\text{faillite} \mid \mathbf{x})$ permet de naviguer entre précision et rappel. Pour **ne pas utiliser le jeu de test** pour choisir ce seuil, la procédure implémentée est la suivante :

1. Génération de **prédictions out-of-fold (OOF)** sur le jeu d’entraînement : à chaque pli, le modèle est entraîné sur une sous-partie du train et les probabilités sont calculées sur la partie tenue à l’écart.
2. Recherche du seuil t^* qui **maximise le F1-score** sur les étiquettes du train alignées avec ces probabilités OOF.
3. Application de t^* aux probabilités du **jeu de test** pour une seconde matrice de confusion et des métriques comparables.

Les valeurs numériques (seuil, F1 OOF, F1 test au seuil t^* , précision et rappel) sont enregistrées dans `output/threshold_metrics.json`.




FIGURE 4 – Courbe précision-rappel sur le **jeu de test**. Ligne de base : proportion de faillites. Point marqué : précision et rappel obtenus sur le test avec le seuil t^* calibré sur le train (OOF).




FIGURE 5 – Matrice de confusion sur le test avec le **seuil optimal** t^* (calibrage F1 sur prédictions OOF du train).

6.3 Interprétation métier

Un **seuil plus bas** augmente le **rappel** (plus de faillites détectées) au prix souvent d'une **précision** plus faible (plus de fausses alertes). Inversement, un seuil plus élevé est plus conservateur. Le choix final doit aussi refléter les **coûts relatifs** des faux négatifs (faillite non vue) et des faux positifs (entreprise saine signalée à tort), selon le contexte bancaire ou d'investissement.

7 Synthèse, limites et pistes

Résumé. Le pipeline combine normalisation, SMOTE sur le train, plusieurs algorithmes, recherche sur grille pour la forêt aléatoire, double lecture des performances (CV sur train + test hold-out), et analyse PR avec seuil calibré sans utiliser le test pour le choix de t^* .

Limites. Les données sont un instantané ; pas de validation temporelle explicite si les entreprises ne sont pas ordonnées dans le temps. La SMOTE crée des exemples synthétiques qui peuvent ne pas refléter des cas extrêmes réels. Les importances de variables peuvent être biaisées en présence de forte colinéarité entre ratios financiers.

Pistes d'extension. Courbe **coût** métier, métrique F_β (favoriser le rappel), **SHAP** pour l'explicabilité locale, calibration des probabilités (**CalibratedClassifierCV**), ou comparaison avec d'autres stratégies de rééchantillonnage dans le même pipeline.

8 Conclusion

La phase modélisation fournit un modèle documenté, des scores de validation croisée pour apprécier la variabilité, et une analyse **précision–rappel** avec **seuil de décision** justifié méthodologiquement. Les figures et fichiers numériques dans **output/** servent de base directe à la soutenance et au rapport final CRISP-DM.