

Phase Modélisation Deep Learning (CRISP-DM)

Prédiction de la faillite d'entreprise – Comparaison de réseaux de neurones
et sélection du meilleur modèle

Jegham Mohamed
Génie Informatique – Data Science
Année universitaire 2025–2026

Table des matières

1	Introduction	2
2	Préparation des données	2
2.1	Prétraitement	2
2.2	Déséquilibre des classes	2
2.3	Corrélations	3
3	Architectures Deep Learning comparées	3
3.1	Modèle 1 – Simple MLP	3
3.2	Modèle 2 – Deep MLP	4
3.3	Modèle 3 – Regularized MLP	4
4	Courbes d'entraînement	4
5	Comparaison des modèles	5
6	Meilleur modèle retenu et justification	5
6.1	Pourquoi ce modèle est le plus adapté	5
6.2	Visualisations du modèle final	6
7	Interprétation métier	7
8	Conclusion	8

1 Introduction

Ce rapport présente la phase **Deep Learning** du projet CRISP-DM de prédiction de faillite d'entreprise. L'objectif est de comparer plusieurs architectures de réseaux de neurones sur le même protocole expérimental et de retenir un modèle final adapté au contexte métier.

Script principal. Toute la chaîne est implémentée dans `deep_learning_bankruptcy.py`.

Données. Le dataset `data.csv` contient 6 819 observations, 95 indicateurs financiers et la variable cible binaire `Bankrupt?` (0 = non-faillite, 1 = faillite).

2 Préparation des données

2.1 Prétraitement

- Nettoyage des noms de colonnes ;
- Imputation des valeurs manquantes par la médiane (si nécessaire) ;
- Découpage **80/20** stratifié (train/test) ;
- Standardisation (`StandardScaler`) ;
- Rééquilibrage du train avec `SMOTE` (pas de `SMOTE` sur le test).

2.2 Déséquilibre des classes




FIGURE 1 – Distribution de la variable cible `Bankrupt?`.

Interprétation. La classe faillite est minoritaire. Sans traitement, un modèle peut obtenir une bonne accuracy en ratant pourtant beaucoup de faillites. Le rééquilibrage par `SMOTE` est donc essentiel en entraînement.

2.3 Corrélations




FIGURE 2 – Matrice de corrélation (top variables les plus liées à la cible).

3 Architectures Deep Learning comparées

Trois réseaux ont été entraînés avec la même logique :

- **Sortie** : Dense(1, sigmoid) ;
- **Loss** : binary_crossentropy ;
- **Optimiseur** : Adam ;
- **Callbacks** : EarlyStopping + ReduceLROnPlateau ;
- **Class weights** pour renforcer la sensibilité à la classe minoritaire.

3.1 Modèle 1 – Simple MLP

Dense(64, relu) → Dense(32, relu) → Dense(1, sigmoid)

3.2 Modèle 2 – Deep MLP

Dense(128) → Dense(64) → Dense(32) → Dense(16) → Dense(1)

3.3 Modèle 3 – Regularized MLP

Dense(128) → BN → Dropout(0.3) → Dense(64) → BN → Dropout(0.3) → Dense(32) → Dense(1)

4 Courbes d'entraînement




FIGURE 3 – Évolution loss/accuracy – Modèle 1 (Simple MLP).




FIGURE 4 – Évolution loss/accuracy – Modèle 2 (Deep MLP).




FIGURE 5 – Évolution loss/accuracy – Modèle 3 (Regularized MLP).

Lecture rapide. Les courbes permettent d’identifier le sur-apprentissage, la stabilité de la validation et l’effet de la régularisation.

5 Comparaison des modèles

Les métriques de test (Accuracy, Precision, Recall, F1-score, ROC-AUC) sont exportées dans `model_results.csv`. Le classement est fait par **F1-score**, puis ROC-AUC.

Pourquoi F1-score ? Dans un contexte de classes déséquilibrées, le F1-score est plus pertinent que l’accuracy car il pénalise à la fois les faux positifs et les faux négatifs.

Modèle	Accuracy	Precision	Recall	F1	ROC-AUC
MODEL 3 - Regularized MLP	0.9552	0.3508	0.4545	0.39606	0.8564
MODEL 2 - Deep MLP	0.9618	0.4047	0.3863	0.3953	0.8166
MODEL 1 - Simple MLP	0.9582	0.3488	0.3409	0.3448	0.8602

TABLE 1 – Comparaison des modèles Deep Learning sur le jeu de test (générée automatiquement depuis `model_results.csv`).

6 Meilleur modèle retenu et justification

Le meilleur modèle est sauvegardé automatiquement sous `best_model.keras`. Le choix se fait sur le **F1-score** maximal.

6.1 Pourquoi ce modèle est le plus adapté

- Meilleur compromis précision/rappel (critique pour la détection de faillite) ;
- Bonne capacité de discrimination (ROC-AUC) ;
- Comportement stable observé sur les courbes train/validation ;
- Adapté au risque métier : limiter les **faux négatifs** (faillites non détectées).

6.2 Visualisations du modèle final




FIGURE 6 – Matrice de confusion – meilleur modèle.




FIGURE 7 – Courbe ROC – meilleur modèle.




FIGURE 8 – Importance des variables via SHAP (summary bar).

7 Interprétation métier

- **Déséquilibre de classes** : la faillite est rare ; un modèle naïf peut sembler bon mais être dangereux en pratique.
- **Métrique clé** : le F1-score est prioritaire pour équilibrer précision et rappel.
- **Coût des faux négatifs** : ne pas détecter une entreprise en risque peut induire pertes de créance, sous-estimation du risque et mauvaise allocation de capital.
- **SMOTE + class_weight** : combinaison utile pour renforcer l'apprentissage de la classe minoritaire.

8 Conclusion

La phase Deep Learning fournit :

- une comparaison claire de trois architectures MLP ;
- une sélection objective du meilleur modèle ;
- des visualisations de performance et d’explicabilité ;
- un modèle final exporté et prêt pour les étapes suivantes (seuil métier, monitoring, déploiement).

Compilation. Exécuter d’abord :

```
python deep_learning_bankruptcy.py
```

puis compiler ce rapport :

```
pdflatex rapport_deep_learning.tex
```